

Caracterizando a atividade de *code review* no GitHub

Luiz Paulo Gonçalves Arthur Curi Kramberger
Hélio Ernesto Gouvea Dutra Teixeira
PUC Minas – Laboratório de Experimentação de Software
Prof. Danilo de Quadros Maia Filho

14 de maio de 2026

Resumo

Este trabalho caracteriza a atividade de *code review* em repositórios populares do GitHub, sob a perspectiva de quem submete código. Coletamos 12.979 *Pull Requests* a partir de 192 repositórios entre os 200 mais populares por estrelas, contemplando apenas PRs com status MERGED ou CLOSED, pelo menos uma revisão registrada e tempo de análise superior a uma hora. Analisamos oito questões de pesquisa em duas dimensões: o *feedback* final da revisão (MERGED vs. CLOSED) e o número de revisões realizadas, considerando como variáveis independentes o tamanho do PR, o tempo de análise, a riqueza da descrição e o volume de interações. Utilizamos o teste de correlação de Spearman, adequado a dados não-normais e à presença de *outliers*, e reportamos coeficiente ρ e p -valor para cada RQ.

1 Introdução

Revisão de código (*code review*) tornou-se prática central no desenvolvimento moderno, especialmente em projetos *open source* hospedados no GitHub. Por meio de *Pull Requests*, contribuidores submetem mudanças que são discutidas, comentadas e eventualmente aceitas (*merged*) ou rejeitadas (*closed*). Compreender quais características dos PRs influenciam a aceitação e a quantidade de revisões recebidas é fundamental para que submissores escrevam contribuições mais efetivas.

Neste trabalho buscamos responder a oito questões de pesquisa organizadas em duas dimensões: (A) o *feedback* final da revisão — representado pelo status MERGED ou CLOSED — e (B) o número de revisões (*reviews*) registradas no PR. Em cada dimensão consideramos quatro variáveis independentes: tamanho, tempo de análise, descrição e interações.

Hipóteses informais. Antes de coletar os dados, formulamos as seguintes expectativas para cada RQ:

RQ01: PRs maiores tendem a introduzir mais riscos e demandam revisão mais detalhada, logo esperamos que PRs com maior número de arquivos alterados (e mais linhas modificadas) tenham menor probabilidade de serem aceitos.

RQ02: Esperamos correlação negativa: PRs que permanecem muito tempo em revisão costumam indicar discussões prolongadas ou problemas que tendem a culminar em fechamento sem merge.

RQ03: Esperamos correlação positiva: descrições mais detalhadas fornecem contexto aos revisores e facilitam a aceitação do PR.

RQ04: Esperamos efeito misto: por um lado mais participantes e comentários indicam atenção ao PR; por outro, podem refletir controvérsia e questionamentos, podendo correlacionar-se negativamente com o merge.

RQ05: Esperamos correlação positiva: PRs maiores tendem a passar por mais rodadas de revisão.

RQ06: Esperamos correlacao positiva: quanto mais tempo em revisao, maior a oportunidade de novas revisoes ocorrerem.

RQ07: Esperamos correlacao negativa (ou pequena): descricoes ricas reduziriam duvidas e, portanto, a necessidade de rodadas adicionais de revisao.

RQ08: Esperamos correlacao positiva: PRs com mais participantes e comentarios devem demandar mais revisoes.

2 Metodologia

Construção do *dataset*

Os dados foram obtidos via API GraphQL do GitHub (<https://api.github.com/graphql>). Inicialmente listamos os 200 repositórios públicos com mais estrelas, mantendo apenas aqueles com pelo menos 100 *Pull Requests* no estado MERGED ou CLOSED. Para cada repositório coletamos os *Pull Requests* mais recentes até o limite configurável `PR_LIMIT_PER_REPO` (configurado como 200 nesta execução), parametro que explicitamente controla o tempo de execução da coleta.

Aplicamos os seguintes filtros sobre cada PR:

- status MERGED ou CLOSED;
- pelo menos uma revisão registrada (`reviews.totalCount ≥ 1`);
- tempo de análise superior a uma hora — diferença entre `createdAt` e a última atividade (`mergedAt` ou `closedAt`). Esse critério elimina PRs revisados de forma automática por *bots* ou CI.

A coleta é robusta: trata *rate limit* primário (pausa até `resetAt` quando o orçamento de pontos está baixo), *secondary rate limit* (*retry* com *backoff* exponencial), e mantém *checkpoint* por repositório (arquivos JSON em `data/checkpoints/`), permitindo retomar de onde parou em caso de interrupção.

Após o filtro, o *dataset* final contém 12.979 PRs distribuídos em 192 repositórios, dos quais 9.845 foram aceitos (MERGED) e 3.134 rejeitados (CLOSED).

Métricas por PR

- **Tamanho:** número de arquivos alterados (`changedFiles`) e total de linhas adicionadas mais removidas (`additions + deletions`).
- **Tempo de análise:** intervalo em horas entre `createdAt` e `mergedAt/closedAt`.
- **Descrição:** número de caracteres do corpo do PR (`bodyText`).
- **Interações:** `participants.totalCount` e `comments.totalCount`.
- **Número de revisões:** `reviews.totalCount`.

Análise estatística

Para cada RQ resumizamos pelos valores *medianos* sobre todos os PRs do *dataset* (sem agregar por repositório). Adotamos o teste de **correlação de Spearman** pelos seguintes motivos: (i) as distribuições das métricas são fortemente assimétricas e apresentam *outliers* (tamanho e tempo costumam ter cauda longa); (ii) não há evidência de normalidade — requisito do teste de Pearson; (iii) Spearman captura relações monotônicas (e não apenas estritamente lineares), o que é mais aderente à natureza dos dados de *code review*.

Para as RQs da dimensão A (status como variável dependente) codificamos o status como binário (MERGED=1, CLOSED=0) e calculamos ρ e p -valor entre a métrica e o status; também reportamos as medianas das métricas por grupo (MERGED vs. CLOSED). Para as RQs da dimensão B aplicamos Spearman diretamente entre a métrica e `reviews.totalCount`.

3 Resultados

A Tabela 1 apresenta as medianas das métricas, globais e por status. A Tabela 2 resume as correlações de Spearman para as oito RQs.

Tabela 1: Medianas das métricas globais e por status do PR.

Métrica	Geral	MERGED	CLOSED
Arquivos alterados	2,00	2,00	1,00
Linhas alteradas (additions + deletions)	37,00	38,00	32,00
Tempo de analise (horas)	32,02	24,50	102,03
Tamanho da descricao (caracteres)	659,00	640,00	696,50
Numero de participantes	2,00	2,00	2,00
Numero de comentarios	1,00	1,00	2,00
Numero de revisoes	1,00	2,00	1,00

Tabela 2: Resumo das 8 RQs: correlação de Spearman entre cada métrica e a variável dependente.

RQ	Métrica	ρ	p -valor	n
RQ01	arquivos alterados	0,1089	< 0,0001	12.979
RQ01	linhas alteradas (additions + deletions)	0,0299	0,0006	12.979
RQ02	tempo de analise (horas)	-0,2272	< 0,0001	12.979
RQ03	tamanho da descricao (caracteres)	-0,0167	0,0576	12.979
RQ04	numero de participantes	-0,0205	0,0194	12.979
RQ04	numero de comentarios	-0,0808	< 0,0001	12.979
RQ05	arquivos alterados	0,2450	< 0,0001	12.979
RQ05	linhas alteradas (additions + deletions)	0,2909	< 0,0001	12.979
RQ06	tempo de analise (horas)	0,0777	< 0,0001	12.979
RQ07	tamanho da descricao (caracteres)	0,1787	< 0,0001	12.979
RQ08	numero de participantes	0,3504	< 0,0001	12.979
RQ08	numero de comentarios	0,2899	< 0,0001	12.979

3.1 Dimensão A – *Feedback* final (MERGED vs. CLOSED)

RQ01

Para arquivos alterados, a mediana entre PRs aceitos (MERGED) foi 2,00 e entre rejeitados (CLOSED) foi 1,00. A correlação de Spearman com o status (MERGED=1, CLOSED=0) resultou em $\rho = 0,1089$ ($p < 0,0001$). Veja a Figura 1. Para linhas alteradas (additions + deletions), a mediana entre PRs aceitos (MERGED) foi 38,00 e entre rejeitados (CLOSED) foi 32,00. A correlação de Spearman com o status (MERGED=1, CLOSED=0) resultou em $\rho = 0,0299$ ($p = 0,0006$). Veja a Figura 2.




Figura 1: RQ01 - arquivos alterados




Figura 2: RQ01 - linhas alteradas (additions + deletions)

RQ02

Para tempo de análise (horas), a mediana entre PRs aceitos (MERGED) foi 24,50 e entre rejeitados (CLOSED) foi 102,03. A correlação de Spearman com o status (MERGED=1, CLOSED=0) resultou em $\rho = -0,2272$ ($p < 0,0001$). Veja a Figura 3.




Figura 3: RQ02 - tempo de análise (horas)

RQ03

Para tamanho da descrição (caracteres), a mediana entre PRs aceitos (MERGED) foi 640,00 e entre rejeitados (CLOSED) foi 696,50. A correlação de Spearman com o status (MERGED=1, CLOSED=0) resultou em $\rho = -0,0167$ ($p = 0,0576$). Veja a Figura 4.




Figura 4: RQ03 - tamanho da descrição (caracteres)

RQ04

Para numero de participantes, a mediana entre PRs aceitos (MERGED) foi 2,00 e entre rejeitados (CLOSED) foi 2,00. A correlação de Spearman com o status (MERGED=1, CLOSED=0) resultou em $\rho = -0,0205$ ($p = 0,0194$). Veja a Figura 5. Para numero de comentarios, a mediana entre PRs aceitos (MERGED) foi 1,00 e entre rejeitados (CLOSED) foi 2,00. A correlação de Spearman com o status (MERGED=1, CLOSED=0) resultou em $\rho = -0,0808$ ($p < 0,0001$). Veja a Figura 6.




Figura 5: RQ04 - numero de participantes




Figura 6: RQ04 - numero de comentarios

3.2 Dimensão B – Número de revisões

RQ05

Para arquivos alterados, a correlação de Spearman com o número de revisões resultou em $\rho = 0,2450$ ($p < 0,0001$). Veja a Figura 7. Para linhas alteradas (additions + deletions), a correlação de Spearman com o número de revisões resultou em $\rho = 0,2909$ ($p < 0,0001$). Veja a Figura 8.




Figura 7: RQ05 - arquivos alterados




Figura 8: RQ05 - linhas alteradas (additions + deletions)

RQ06

Para tempo de analise (horas), a correlação de Spearman com o número de revisões resultou em $\rho = 0,0777$ ($p < 0,0001$). Veja a Figura 9.




Figura 9: RQ06 - tempo de analise (horas)

RQ07

Para tamanho da descricao (caracteres), a correlação de Spearman com o número de revisões resultou em $\rho = 0,1787$ ($p < 0,0001$). Veja a Figura 10.




Figura 10: RQ07 - tamanho da descricao (caracteres)

RQ08

Para numero de participantes, a correlação de Spearman com o número de revisões resultou em $\rho = 0,3504$ ($p < 0,0001$). Veja a Figura 11. Para numero de comentarios, a correlação de Spearman com o número de revisões resultou em $\rho = 0,2899$ ($p < 0,0001$). Veja a Figura 12.




Figura 11: RQ08 - numero de participantes




Figura 12: RQ08 - numero de comentarios

3.3 Visão geral das correlações




Figura 13: Heatmap de correlações (Spearman) entre todas as métricas.

4 Discussão

Nesta seção confrontamos as hipóteses iniciais com os valores observados. Adotamos a seguinte convenção de intensidade para $|\rho|$: muito fraca ($< 0,1$), fraca ($< 0,3$), moderada ($< 0,5$), forte ($< 0,7$) e muito forte ($\geq 0,7$).

RQ01

Hipótese inicial: PRs maiores tendem a introduzir mais riscos e demandam revisão mais detalhada, logo esperamos que PRs com maior número de arquivos alterados (e mais linhas modificadas) tenham menor probabilidade de serem aceitos. Para arquivos alterados, obtivemos $\rho = 0,1089$ (intensidade fraca, direção positiva); hipótese refutada. Para linhas alteradas (additions + deletions), obtivemos $\rho = 0,0299$ (intensidade muito fraca, direção positiva); hipótese não se confirma (correlação desprezível).

RQ02

Hipótese inicial: Esperamos correlação negativa: PRs que permanecem muito tempo em revisão costumam indicar discussões prolongadas ou problemas que tendem a culminar em fechamento sem merge. Para tempo de análise (horas), obtivemos $\rho = -0,2272$ (intensidade fraca, direção negativa); hipótese confirmada.

RQ03

Hipótese inicial: Esperamos correlação positiva: descrições mais detalhadas fornecem contexto aos revisores e facilitam a aceitação do PR. Para tamanho da descrição (caracteres), obtivemos $\rho = -0,0167$ (intensidade muito fraca, direção negativa); hipótese não se confirma (correlação desprezível).

RQ04

Hipótese inicial: Esperamos efeito misto: por um lado mais participantes e comentários indicam atenção ao PR; por outro, podem refletir controvérsia e questionamentos, podendo correlacionar-se negativamente com o merge. Para número de participantes, obtivemos $\rho = -0,0205$ (intensidade muito fraca, direção negativa); hipótese compatível (hipótese era mista). Para número de comentários, obtivemos $\rho = -0,0808$ (intensidade muito fraca, direção negativa); hipótese compatível (hipótese era mista).

RQ05

Hipótese inicial: Esperamos correlação positiva: PRs maiores tendem a passar por mais rodadas de revisão. Para arquivos alterados, obtivemos $\rho = 0,2450$ (intensidade fraca, direção positiva); hipótese confirmada. Para linhas alteradas (additions + deletions), obtivemos $\rho = 0,2909$ (intensidade fraca, direção positiva); hipótese confirmada.

RQ06

Hipótese inicial: Esperamos correlação positiva: quanto mais tempo em revisão, maior a oportunidade de novas revisões ocorrerem. Para tempo de análise (horas), obtivemos $\rho = 0,0777$ (intensidade muito fraca, direção positiva); hipótese confirmada.

RQ07

Hipótese inicial: Esperamos correlação negativa (ou pequena): descrições ricas reduziram dúvidas e, portanto, a necessidade de rodadas adicionais de revisão. Para tamanho da descrição (caracteres), obtivemos $\rho = 0,1787$ (intensidade fraca, direção positiva); hipótese refutada.

RQ08

Hipótese inicial: Esperamos correlação positiva: PRs com mais participantes e comentários devem demandar mais revisões. Para número de participantes, obtivemos $\rho = 0,3504$ (intensidade moderada, direção positiva); hipótese confirmada. Para número de comentários, obtivemos $\rho = 0,2899$ (intensidade fraca, direção positiva); hipótese confirmada.

5 Conclusão

Caracterizamos a atividade de *code review* em 192 repositórios populares do GitHub analisando 12.979 *Pull Requests* sob duas dimensões: o *feedback* final (MERGED vs. CLOSED) e o número de revisões. As principais observações estão sumarizadas na Tabela 2 e nas Figuras correspondentes a cada RQ.

Como limitações destacam-se: (i) o teto de 192 repositórios e o limite `PR_LIMIT_PER_REPO` podem não representar comunidades de menor visibilidade; (ii) o filtro de tempo $> 1h$, embora elimine ruídos de *bots*, pode descartar PRs triviais legítimos; (iii) o uso de *Spearman* captura monotonicidade, mas não implica causalidade. Trabalhos futuros podem incorporar análises multivariadas e estratificação por linguagem ou domínio do repositório.